

Algorithme de prédiction des scores

Modèle de Poisson binaire v4 — Staging

1. Vue d'ensemble

Le modèle prédit le score de chaque match à venir en modélisant les buts de chaque équipe comme deux variables aléatoires **indépendantes** suivant une loi de Poisson de paramètres λ_A et λ_B . La distribution jointe donne la probabilité de chaque score exact :

$$P(A=i, B=j) = \text{Poisson}(i, \lambda_A) \times \text{Poisson}(j, \lambda_B)$$

Les paramètres λ sont construits en deux temps : un **prior FIFA** basé sur le classement officiel (avant tout match), puis une **régression bayésienne** qui intègre progressivement les statistiques réelles au fil des matchs joués.

2. Prior FIFA

Avant tout match joué, chaque équipe reçoit des valeurs attendues de buts basées sur ses **points FIFA officiels du 11 juin 2026** (veille du tournoi). Les 48 équipes qualifiées ont des ratings de 1 342 (Curaçao) à 1 877 (Argentine), pour une moyenne $\text{avgFifa} \approx 1\,580$.

$$\begin{aligned} \text{priorGF_A} &= \text{avgGF} \times (\text{fifaA} / \text{avgFifa}) ^ 1.5 \\ \text{priorGA_A} &= \text{avgGA} \times (\text{avgFifa} / \text{fifaA}) ^ 1.5 \end{aligned}$$

L'exposant **1.5** différencie suffisamment les équipes sans créer d'écart irréaliste. Exemples de prédictions en prior pur (aucun match joué) :

Confrontation	λ_A	λ_B	P(Vic. A)
Argentine (1877) vs Curaçao (1342)	2.05	0.78	~74 %
France (1855) vs Brésil (1765)	1.65	1.48	~42 %
Maroc (1750) vs Écosse (1490)	1.62	1.05	~58 %
Mexique (1705) vs Haïti (1398)	1.74	0.93	~65 %

3. Régression bayésienne (K = 6)

Au fil des matchs joués, les statistiques réelles viennent progressivement remplacer le prior FIFA selon un schéma de mélange pondéré (Bayesian shrinkage) :

$$\begin{aligned} w &= \text{matchs_joués} / (\text{matchs_joués} + K) \quad \text{avec } K = 6 \\ \text{gf_A} &= w \times \text{rawGF_A} + (1 - w) \times \text{priorGF_A} \\ \text{ga_A} &= w \times \text{rawGA_A} + (1 - w) \times \text{priorGA_A} \end{aligned}$$

Matches joués	Poids stats réelles (w)	Poids prior FIFA (1 - w)
0 (avant tournoi)	0 %	100 %
1 (après J1)	14 %	86 %
2 (après J2)	25 %	75 %
3 (après J3)	33 %	67 %
6	50 %	50 %

■ $K=6$ évite qu'un J1 difficile (ex : Maroc 0-2 Brésil) écrase le prior d'une équipe classée top-10. Avec $K=3$ (version précédente), une seule défaite rendait l'Écosse favorite contre le Maroc — résultat incohérent avec le classement FIFA.

4. Calcul des λ (buts attendus)

Les lambdas croisent l'efficacité offensive d'une équipe avec la faiblesse défensive de l'adversaire, normalisés par la moyenne du tournoi :

```
avgGF = total_buts_marqués / total_matches_joués
        (≈ 1.3 - 1.6 en phase de groupes)

λA = clip( gf_A × ga_B / avgGF , min=0.2, max=4.0 )
λB = clip( gf_B × ga_A / avgGF , min=0.2, max=4.0 )
```

Le clip [0.2 ; 4.0] empêche des prédictions aberrantes lorsqu'une équipe n'a joué qu'un seul match (ex : 5 buts en J1 → λ serait irréaliste sans plafonnement).

5. Distribution des scores (grille 8×8)

On calcule la probabilité de chaque score exact (i, j) de (0,0) à (7,7), ce qui couvre plus de 99,9 % de la masse de probabilité :

```
pour i de 0 à 7, j de 0 à 7 :
    P(i, j) = e^(-λA) × λA^i / i! × e^(-λB) × λB^j / j!

P(Victoire A) = Σ P(i, j) pour i > j
P(Nul)        = Σ P(i, j) pour i = j
P(Défaite A)  = Σ P(i, j) pour i < j
```

6. Score prédit — argmax par catégorie (correctif clé)

Sans correctif, le score globalement le plus probable est toujours **1-1** car c'est le score le plus fréquent selon Poisson avec $\lambda \approx 1.3$, même quand une équipe a 50% de chance de gagner. Le score prédit serait donc toujours nul.

La solution : chercher le score le plus probable **dans chaque catégorie séparément** (Victoire / Nul / Défaite), puis afficher le score de la catégorie dont la probabilité totale est la plus haute :

```

bestW = argmax P(i,j)   pour i > j   → ex: 2-1
bestD = argmax P(i,j)   pour i = j   → ex: 1-1
bestL = argmax P(i,j)   pour i < j   → ex: 0-2

si P(Vic.A) ≥ P(Nul) et P(Vic.A) ≥ P(Déf.A) → afficher bestW
si P(Nul) est maximum                       → afficher bestD
sinon                                       → afficher bestL

```

■ Exemple : Maroc vs Écosse — $P(V)=48\%$, $P(N)=25\%$, $P(D)=27\%$. Sans correctif → 1-1 affiché. Avec correctif → 1-0 affiché (meilleur score dans la catégorie Victoire).

7. Filtre et affichage

Les prédictions sont calculées uniquement pour les matchs à venir :

Condition	Traitement
match.isFT = true (terminé)	Exclu — score réel affiché
match.isLive = true (en cours)	Exclu — score live affiché
Placeholder KO ("1er Gr.A", "V M73"...)	Exclu via regex <code>_PRED_SKIP</code>
hasStats = true (≥ 1 match joué par équipe)	Affiché en orange
hasStats = false (J1 pas encore joué)	Affiché en gris

8. Limites et pistes d'amélioration

Limites actuelles

- **Indépendance des buts** : le modèle suppose que les buts de A et B sont indépendants, ce qui est une approximation (en réalité le score influence le jeu).
- **K fixe** : $K=6$ constant signifie qu'en J3 (3 matchs joués), le prior FIFA domine encore à 67 %. Un K décroissant convergerait plus vite vers les stats réelles en fin de phase de groupes.
- **Pas de contexte** : blessures, suspensions, importance de la rencontre (déjà qualifié ?), terrain neutre vs effectif local, ne sont pas pris en compte.
- **Pas de côtes de paris** : les marchés bookmakers intègrent toutes ces informations contextuel les et constituent un signal fort.

Pistes d'amélioration

- **K adaptatif** : $K = \max(2, 6 - \text{matchs_joués})$ pour converger plus vite vers les stats réelles en J3.
- **Côtes bookmakers** via The Odds API injectées comme prior supplémentaire.
- **xG (expected goals)** plutôt que buts réels pour les λ , moins sensible aux performances exceptionnelles d'un seul match.